A/B test sandbox

Руководство: как читать интерфейс и результаты

Это песочница для обучения. Вы сами задаёте **«правду»** (например, «в варианте B конверсия на 10% выше»), приложение генерирует фейковых пользователей, а затем статистика пытается эту правду угадать. В реальном тесте правду знать нельзя. Здесь можно, и в этом ценность: всегда видно разницу между **«что есть на самом деле»** и **«что показал тест»**.

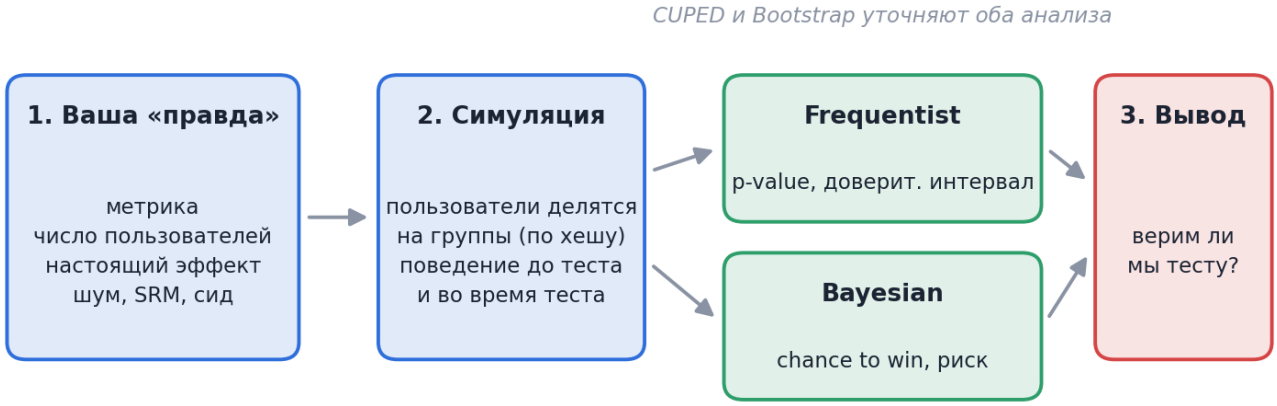


Рис. 1. Как устроено приложение: вы задаёте правду, симуляция генерирует данные, два вида статистики дают вывод.

Запуск

nvm use (нужен Node 22), затем **yarn dev**. Адрес: http://localhost:3002. Тесты: **yarn test**.

Быстрый старт за 2 минуты

Шаг	Что делать	Что вы увидите
1	Откройте вкладку **Experiment**	Слева параметры, справа результаты. По умолчанию: conversion 10%, настоящий эффект +10% (10% → 11%), 10 000 пользователей
2	Посмотрите карточку **Frequentist**	p-value ≈ 0.26, «не значимо». Эффект на самом деле есть, но выборки мало
3	Посмотрите карточку **Bayesian**	Chance to win ≈ 86%. Те же данные, другой вопрос
4	Нажмите **New run** несколько раз	Результат каждый раз немного другой. Это и есть шум

> **Главное правило**
> Один прогон ничего не доказывает. Всегда смотрите на разброс: нажимайте New run несколько раз.

1. Левая панель: каждый контрол

Контрол	Что делает	На что влияет
Metric	Conversion, Click или Revenue per user	От типа метрики зависит тест: z-test для долей, Welch t-test для revenue
Users	Сколько пользователей участвует (200–100 000)	Больше пользователей: уже интервалы, меньше шум, выше мощность
Baseline rate	Значение метрики в контроле (для revenue: Purchase rate)	Масштаб метрики. Чем ниже, тем больше пользователей нужно
True effect (relative)	Настоящий эффект. +10% при baseline 10% значит 10% → 11%	Это «правда», которую тест должен найти. 0% даёт A/A тест
Treatment share (planned)	План: какую долю трафика отдаём в treatment	Задаёт и фактическую долю (нижний ползунок подтягивается)
Treatment share (actual)	Какая доля реально попала в treatment	Если отличается от плана, срабатывает SRM-алерт
Average order value, Tail heaviness	Только для revenue: средний чек и «тяжесть хвоста» (sigma)	Чем больше sigma, тем чаще редкие огромные заказы и тем шумнее метрика
Pre-experiment correlation	Насколько поведение до теста похоже на поведение во время теста	Только на CUPED. Реальная корреляция видна в панели CUPED и ниже заданной
Alpha	Порог значимости (0.01 / 0.05 / 0.1)	Порог для p-value, ширина интервалов, красные линии на графиках, критерии в A/A, мощность
Seed	Номер «случайности». Один seed: одни и те же пользователи	Воспроизводимость
Apply CUPED	Переключает анализ на скорректированные данные	Обе карточки результатов и bootstrap
Informative Bayesian prior	Включает prior: «до теста я верю, что эффект близок к 0». Ползунок sd: чем меньше, тем строже	Только Bayesian-числа
New run	Ставит случайный seed	Всё пересчитывается на новых случайных пользователях

Полезно знать
Conversion и Click в симуляции устроены одинаково (да/нет на пользователя), разница только в названии. В **Revenue** пользователь покупает с вероятностью baseline, а размер чека случайный с тяжёлым хвостом. Эффект влияет **только на вероятность покупки**, чек не меняется. Если оставить seed и двигать ползунок эффекта, случайные числа почти те же, и видно именно влияние параметра. Чтобы увидеть шум, нажимайте New run.

2. Как читать результаты

Две карточки отвечают на **разные вопросы**. Это самое важное отличие.

	Frequentist	Bayesian
Вопрос	Если на самом деле эффекта нет, насколько удивительны такие данные?	Какова вероятность, что B лучше A, и сколько я потеряю, если ошибусь?
Главное число	p-value	Chance to win и risk

	Frequentist	Bayesian
Интервал	Confidence interval: правило, дающее интервал, накрывающий истину в 95% повторений	Credible interval: с вероятностью 95% настоящий эффект внутри (читается буквально)
Решение	Значимо / не значимо (порог alpha)	Chance to win ≥ 95% и risk < 0.25% (пороги GrowthBook)

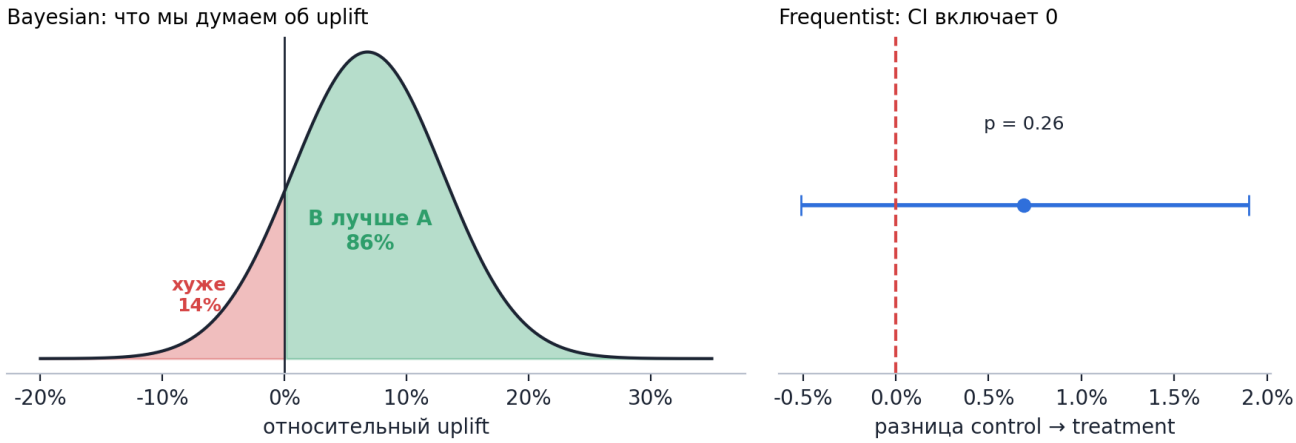


Рис. 2. Настройки по умолчанию (seed 1). Слева: апостериорное распределение uplift, площадь справа от нуля = chance to win (86%). Справа: CI для разницы включает 0, поэтому p = 0.26.

Карточка Frequentist

Число	Что означает
Control / Treatment (n=…)	Значение метрики и размер группы. Ровно 50/50 почти никогда не бывает, это нормально (хеш-распределение)
Uplift	Относительная разница (Treatment − Control) / Control. Это **измеренный** эффект, он шумный. Настоящий задан ползунком
p-value	Вероятность увидеть такую (или большую) разницу, **если настоящего эффекта нет**. Зелёный при p < alpha. Это **не** вероятность того, что B лучше
CI (absolute diff)	Интервал для абсолютной разницы (в пунктах метрики). Включает 0, значит p ≥ alpha, и наоборот
SRM p-value	Проверка, что распределение по группам совпадает с планом. Красный при p < 0.001: **результатам верить нельзя**
Заголовок (z-test / Welch)	z-test для conversion и click, Welch t-test для revenue и для данных после CUPED

Карточка Bayesian

Число	Что означает
Chance to win	Вероятность, что treatment лучше control. Зелёный при ≥ 95%, красный при ≤ 5%
Expected uplift	Средняя ожидаемая относительная разница с учётом prior
Credible interval	С вероятностью (1 − alpha) настоящий относительный эффект внутри этого интервала
Risk if you ship treatment	Сколько в среднем потеряете (в % метрики), если выкатите B, а он на самом деле хуже. Зелёный при < 0.25%
Risk if you keep control	Сколько упустите, если оставите A, а B на самом деле лучше
Verdict	Простая расшифровка chance to win

Prior и цена решения
Prior стягивает оценки к нулю, особенно при малых данных: chance to win уходит ближе к 50%, а интервал сужается. На больших выборках влияние prior пропадает. Вместо бинарного «значимо / не значимо» Bayesian даёт цену решения. Например, chance to win 86% при risk 0.4% можно принять, если выкатка дешёвая и откатываемая.

3. Подсматривание (peeking) и A/A тесты

График **Results over time** показывает, как менялся результат по мере прихода пользователей (40 «подсматриваний»). Переключатель: **p-value** (красная линия = alpha) или **Chance to win** (зелёная линия 95%, красная 5%). Остановка при первой «удаче» даёт ложные победы.

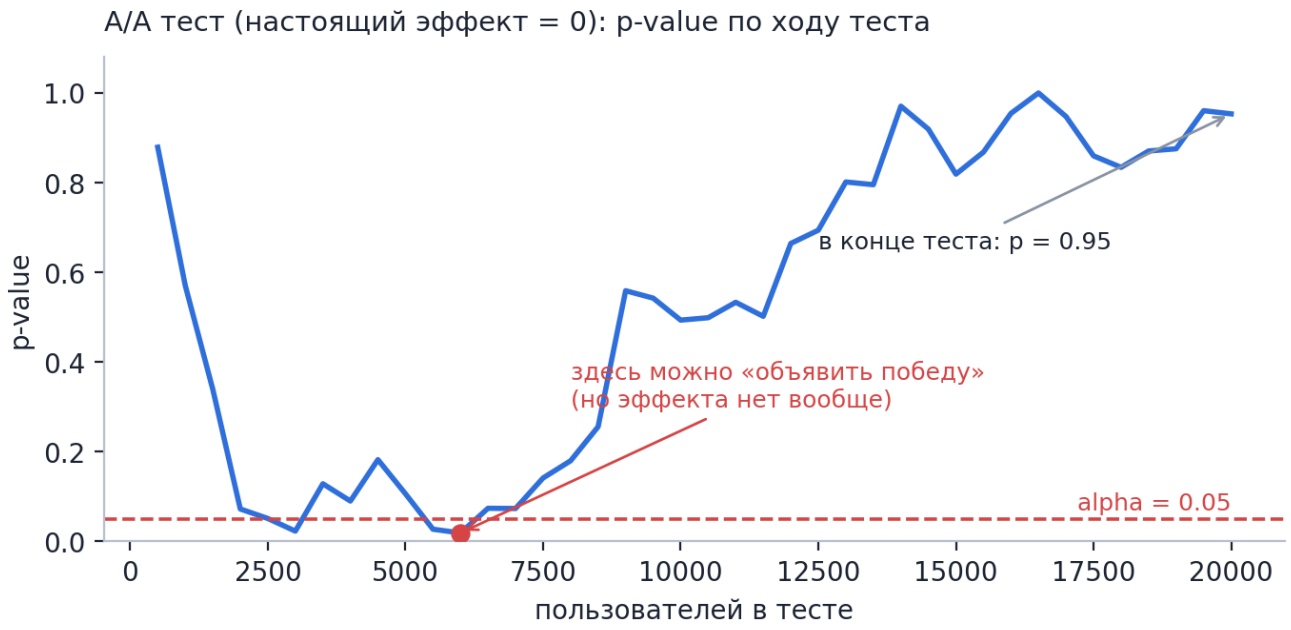


Рис. 3. A/A тест без настоящего эффекта. В какой-то момент p-value проваливается под alpha. Остановись там, и получишь ложную победу. К концу теста p = 0.95.

Панель A/A

Кнопка **Run 300 A/A tests** запускает 300 тестов **без настоящего эффекта** с вашими настройками (users, baseline, metric, alpha) и считает долю ложных побед.

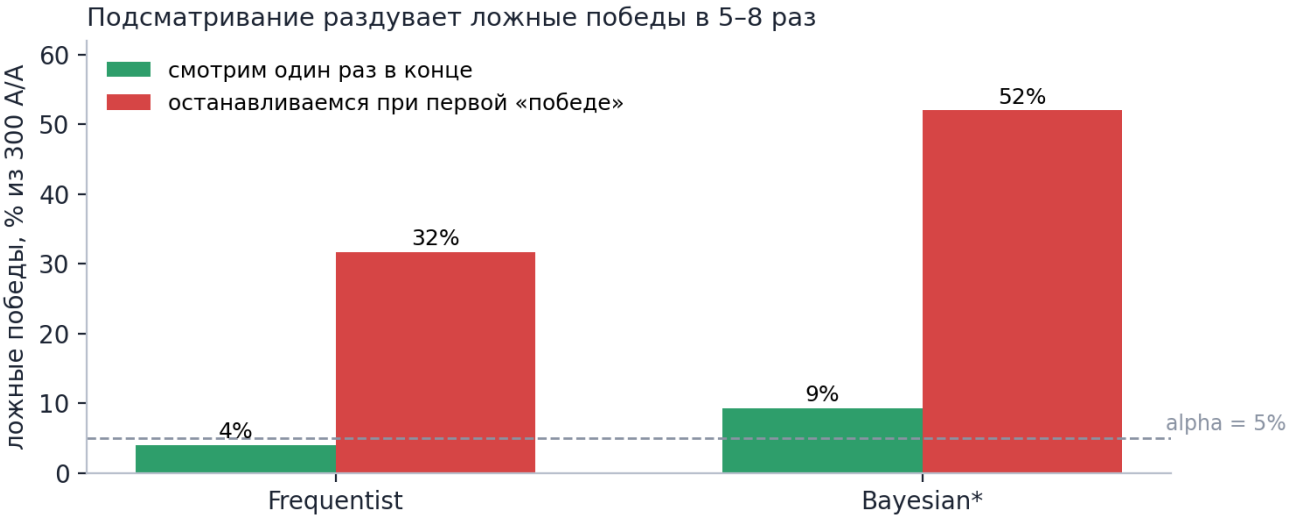


Рис. 4. Результат панели A/A при настройках по умолчанию. *Для Bayesian победитель назначается на обоих краях (≥ 95% или ≤ 5%), поэтому даже при одном взгляде ложных побед около 2×alpha.

Вывод
Если смотреть один раз в заранее запланированный срок, ложных побед ровно столько, сколько обещано (≈ alpha). Если подсматривать и останавливаться при первой удаче, ложных побед в разы больше, **и байесовский подход тут не спасает**.

4. CUPED, Bootstrap и Revenue

CUPED

CUPED использует то, что вы знали о пользователях **до** теста, чтобы вычесть предсказуемую часть шума. Эффект остаётся несмещённым, интервал уже.

Число в панели	Что означает
corr(pre, post)	Реальная корреляция метрики до и во время теста. Чем выше, тем сильнее эффект CUPED
theta	Коэффициент, на который вычитается «до-тестовая» метрика
Variance removed	Доля убранной дисперсии, примерно $corr^2$
CI width without / with CUPED	Ширина интервала. С CUPED должна быть уже

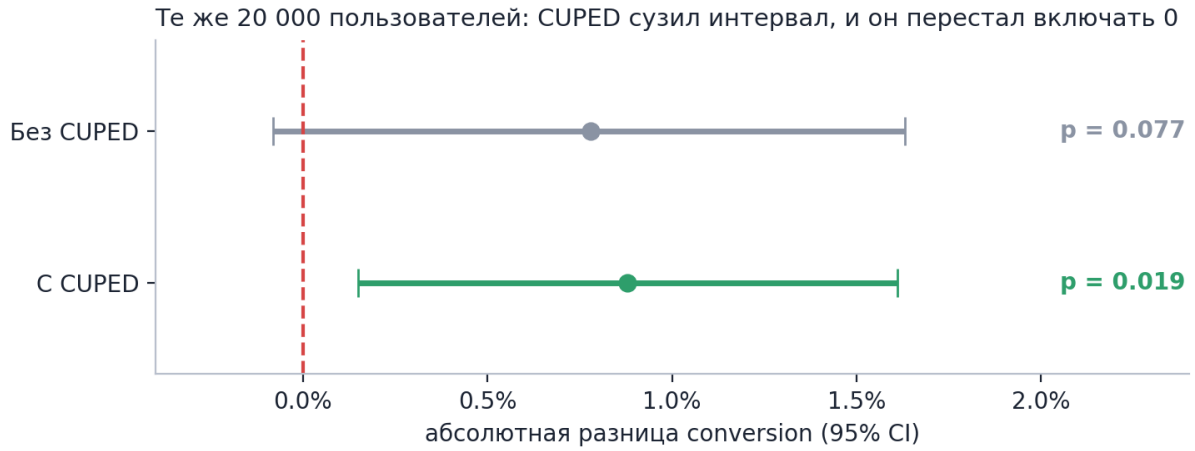


Рис. 5. Conversion, 20 000 пользователей, ползунок корреляции 0.9, seed 1: реальная корреляция ≈ 0.52, убрано ≈ 27% дисперсии.

Подсказка
Ползунок «Pre-experiment correlation» задаёт «скрытую» корреляцию. У бинарных метрик и у revenue реальная корреляция заметно ниже (при 0.9 получается ≈ 0.5), поэтому смотрите на corr(pre, post) в панели CUPED, а не на ползунок.

Bootstrap

Кнопка **Run 1000 resamples** 1000 раз берёт выборку с возвращением из каждой группы и считает разницу средних. Получаются percentile CI, p-value и гистограмма разностей (красная линия = 0). Рядом показан параметрический p-value для сравнения. Метод не предполагает нормальности, поэтому нужен прежде всего для revenue с тяжёлым хвостом. Если после смены параметров появилось «Parameters changed», нажмите кнопку заново.

Revenue и тяжёлый хвост

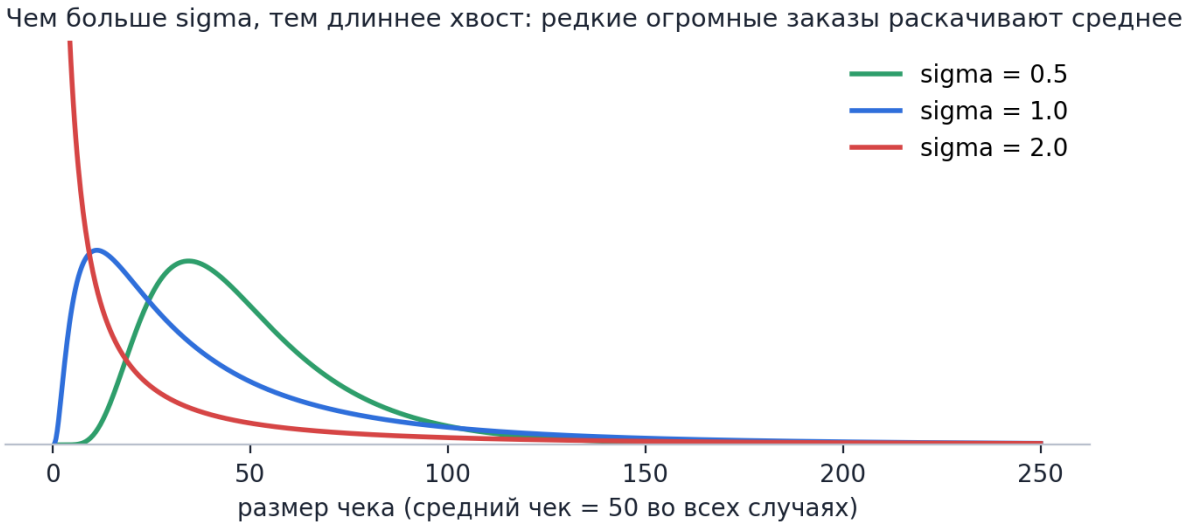


Рис. 6. Распределение размера чека при одинаковом среднем (50). При sigma = 2 медианный чек всего ≈ 7, но редкие огромные заказы раскачивают среднее.

Пример: Revenue, Users 3 000, sigma 2.0, корреляция 0.5. Измеренный uplift огромный (около +58%), но p ≈ 0.15, а интервал примерно от −0.8 до +5.0. Bootstrap даёт ту же картину (p ≈ 0.14). Красивая цифра без интервала ничего не значит.

5. Как всё связано между собой

Что вы меняете	Что происходит в результатах
↑ Users	Интервалы уже, p-value ниже (если эффект есть), chance to win ближе к 100% или 0%, мощность выше
↑ True effect	Измеренный uplift в среднем больше, p-value ниже, chance to win выше. На конкретном прогоне всё равно может не хватить
True effect = 0	Это A/A: p-value «случайное», chance to win гуляет около 50%. Лучший режим для проверки peeking
↓ Baseline	Событий мало, больше шума, нужно больше пользователей
Actual share ≠ planned	SRM p-value краснеет. Остальные цифры могут выглядеть нормально, но им нельзя верить
↑ Tail heaviness (revenue)	Огромная дисперсия, интервалы широкие, t-test и bootstrap расходятся сильнее
↑ Pre-experiment correlation	Сильнее эффект CUPED (если включён Apply CUPED)
Alpha	Меняются порог значимости и ширина интервалов. Сам chance to win не меняется, но меняются credible interval и критерий в A/A
Informative prior	Только Bayesian-числа и график chance to win. Frequentist не трогает
Apply CUPED	Обе карточки и bootstrap считаются на скорректированных данных. График peeking остаётся на сырых
New run / Seed	Те же параметры, другие случайные пользователи

6. Вкладка Power calculator

Отвечает на вопрос **«сколько пользователей нужно до запуска теста?»**. Это самое важное, что надо делать **до** эксперимента.

Контрол	Значение
Metric type	Proportion (conversion, click) или Mean (revenue, время на сайте). Для mean вводятся среднее и стандартное отклонение
Minimum detectable effect	Самый маленький эффект, который важно не пропустить. Вдвое меньше MDE: выборка примерно вчетверо больше
Alpha / Power	Допустимая доля ложных срабатываний (обычно 0.05) и вероятность поймать реальный эффект (обычно 80%)
Eligible users per day	Сколько пользователей в день вы можете запускать в тест (оба варианта вместе)

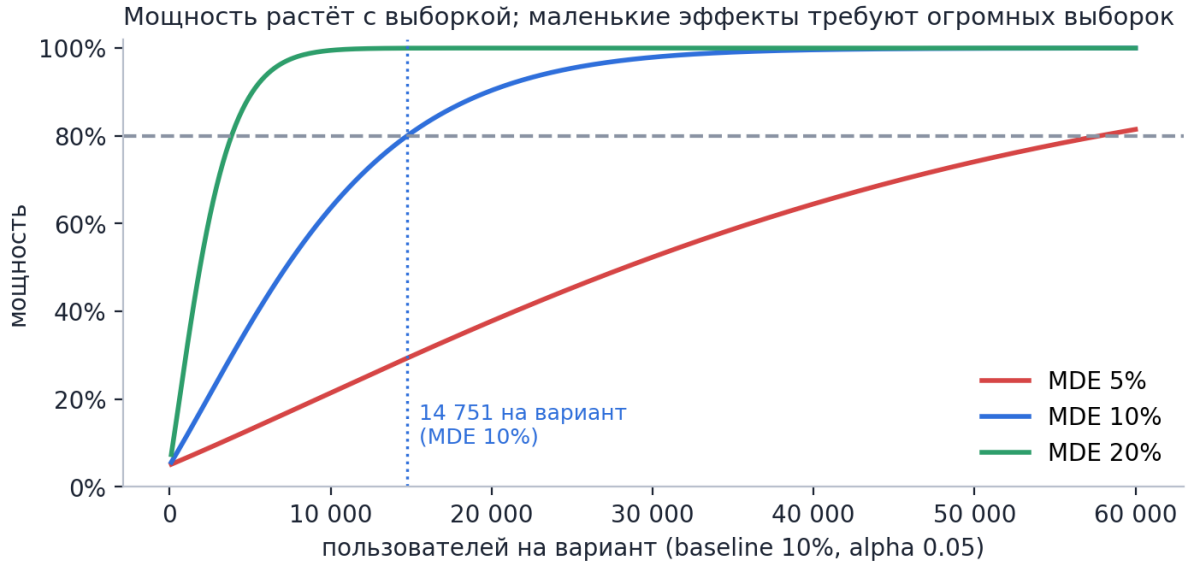


Рис. 7. Мощность против размера выборки. Baseline 10%, MDE 10%, power 80% дают ≈ 14 750 на вариант (≈ 29 500 всего). Поэтому при 10 000 пользователей по умолчанию тест не видит эффект.

7. Упражнения

Нажимайте **New run** несколько раз и смотрите на разброс. Числа даны для seed 1.

#	Тема	Что сделать	Что увидите
1	Недостаточная мощность	Настройки по умолчанию, затем Users = 30 000, несколько раз New run	При 10 000: p ≈ 0.26, хотя эффект настоящий. При 30 000 значимо примерно в 80% прогонов: это и есть «мощность 80%»
2	A/A	Эффект 0%, New run 10 раз, затем панель A/A	p < 0.05 примерно 1 раз из 20. В панели A/A: ≈ 4% против ≈ 32% при peeking
3	Peeking вживую	Эффект 0%, Users 20 000, New run, график p-value	Линия иногда ныряет под красную черту и возвращается. Остановка в этот момент = ложная победа
4	SRM	Treatment share (actual) = 55%	SRM p-value ≈ 0.00000 (красный), группы около 4 500 и 5 500. p-value эффекта при этом выглядит нормально, но верить нельзя
5	CUPED	Conversion, Users 20 000, корреляция 0.9, включить Apply CUPED	p ≈ 0.077 → ≈ 0.019. Реальная корреляция ≈ 0.52, убрано ≈ 27% дисперсии
6	Тяжёлый хвост	Revenue, Users 3 000, sigma 2.0, корреляция 0.5, затем Run 1000 resamples	Uplift ≈ +58%, но p ≈ 0.15 и CI от −0.8 до +5.0. Bootstrap похож (p ≈ 0.14)

#	Тема	Что сделать	Что увидите
7	Prior	Настройки по умолчанию, включить prior, sd от 1 до 0.05	Чем меньше sd, тем сильнее chance to win и expected uplift стягиваются к 50% и 0%

8. Частые ошибки в интерпретации

Ошибка	Как правильно
«p = 0.04, значит с вероятностью 96% B лучше»	Нет. Это вероятность таких данных при отсутствии эффекта. Вероятность «B лучше» даёт Bayesian
«p = 0.26, значит эффекта нет»	Нет. Тест не смог отличить эффект от шума. Смотрите на интервал и мощность
«Остановим тест, как только станет значимо»	Это peeking, он раздувает ложные победы (панель A/A)
«Bayesian не страдает от peeking»	Страдает, если останавливаться по порогу
Один прогон = вывод	Смотрите на много прогонов (New run, панель A/A)
Игнорировать SRM	Если он красный, остальные результаты неважны
Большой uplift без интервала	См. упражнение 6: без интервала цифра ничего не значит

9. Ограничения симулятора

• Эффект одинаковый для всех пользователей, сегментов нет.
• Нет дрейфа во времени и сезонности.
• Нет множественных сравнений и нескольких метрик одновременно.
• Bayesian-движок использует гауссово приближение (как GrowthBook), на очень малых выборках (десятки пользователей) оно грубее.
• График peeking и панель A/A используют сырые данные, CUPED в них не применяется.

10. Глоссарий: термины простым языком

Справочник на случай, когда в интерфейсе или тексте встретилось незнакомое слово. Термины сгруппированы по темам. В правой колонке указано, где это встречается в приложении.

Какой тест для какой метрики

Тип метрики	Пример	Тест в приложении	Почему
Доля (да/нет на пользователя)	Conversion, click rate	z-test для двух долей	Метрика принимает только 0 или 1, а разница долей хорошо описывается нормальным распределением
Среднее по пользователю (непрерывная)	Revenue per user	Welch t-test	Значения разные, дисперсию надо оценивать по данным, а группы могут иметь разный разброс
Любая, особенно с тяжёлым хвостом	Revenue с редкими огромными заказами	Bootstrap (как проверка)	Не предполагает нормальности: распределение разницы строится пересэмплированием
Любая, если известно поведение до теста	Conversion, revenue	Любой из тестов + CUPED	CUPED сначала убирает предсказуемый шум, затем применяется Welch t-test

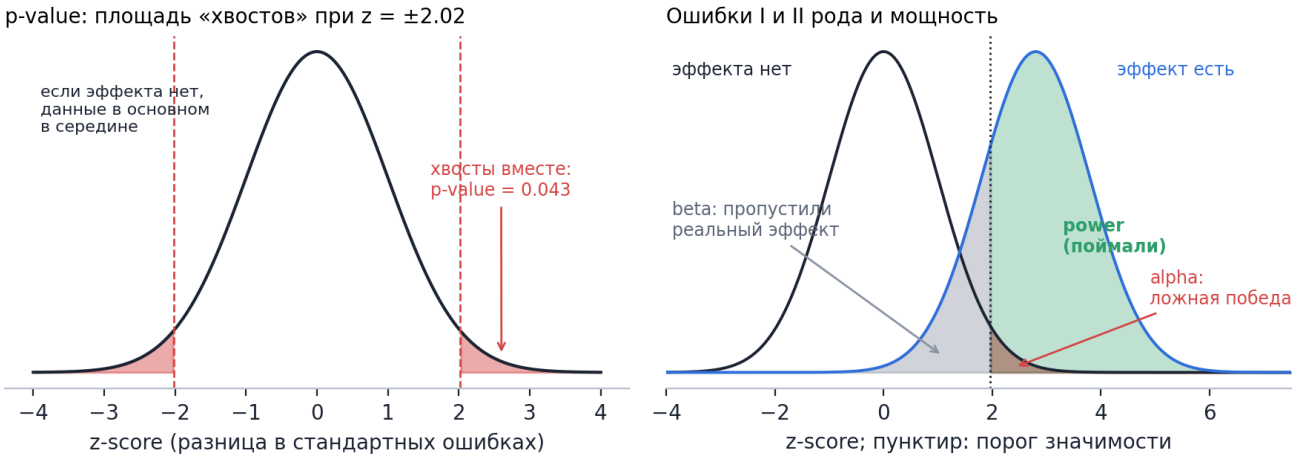


Рис. 8. Слева: p-value, это площадь «хвостов» нормального распределения за наблюдаемым z. Справа: два мира (эффекта нет и эффект есть) и порог значимости, который их разделяет. Красная часть: ложная победа (alpha), серая: пропуск реального эффекта (beta), зелёная: мощность (power = 1 − beta).

Основы эксперимента

Термин	Что это	В приложении
A/B тест	Эксперимент, в котором пользователей случайно делят на группы: одной показывают текущую версию, другой новую. Потом сравнивают метрику	Вся вкладка Experiment
Control и Treatment (A и B)	Control: текущая версия (контрольная группа). Treatment: новая версия (тестовая группа)	Карточки результатов
A/A тест	A/B тест, в котором обе группы получают одно и то же, то есть настоящий эффект равен 0. Используется как проверка честности системы: значимых результатов должно быть примерно alpha (5%). Если больше, значит, в тесте или в статистике ошибка	True effect = 0%, панель A/A
Метрика	Число, по которому судим о результате: доля покупателей, доход на пользователя и т. д.	Metric
Baseline	Значение метрики в контроле до изменения, точка отсчёта	Baseline rate
Uplift (относительный и абсолютный)	Относительный: (B − A) / A. Абсолютный: B − A. Пример: 10% → 11% это +1 процентный пункт (абсолютный) и +10% (относительный)	Uplift в Frequentist (относительный), CI для diff (абсолютный)
Рандомизация, хеш-бакетинг	Случайное, но воспроизводимое распределение по группам. Группа определяется хешем id пользователя, поэтому один человек всегда попадает в один вариант	Распределение в симуляторе
Seed	Начальное число генератора случайных чисел. Один seed даёт одних и тех же «пользователей»	Seed, New run
Выборка и n	Набор пользователей, на которых считаем результат, n означает их число	Users, n= в карточках
Дисперсия, стандартное отклонение (sd)	Меры разброса значений вокруг среднего. Чем больше разброс, тем сложнее заметить эффект	Tail heaviness, CUPED
Стандартная ошибка (SE)	Насколько среднее «гуляет» от выборки к выборке. SE = sd / √n: растёт n, SE падает	Ширина интервалов

Статистические тесты и p-value

Термин	Что это	В приложении
Нулевая гипотеза (H0)	Предположение «эффекта нет, разница возникла случайно». Тест проверяет, насколько данные с ним совместимы. Альтернатива (H1): эффект есть	Основа Frequentist-карточки
p-value	Вероятность увидеть такую (или более сильную) разницу, если на самом деле верна H0. Маленькое значение: данные плохо совместимы с «нет эффекта». Не вероятность того, что B лучше	p-value
Статистическая значимость	Результат, при котором p-value < alpha. Означает только «вряд ли случайность», а не «эффект большой или важный»	Зелёный p-value
z-test	Тест, который считает z = разница / стандартная ошибка, то есть на сколько «стандартных ошибок» разница отличается от нуля, и сверяет это с нормальным распределением. Для сравнения двух долей. Работает хорошо, когда n большое. Правило: $\|z\| > 1.96$ соответствует $p < 0.05$	Conversion, click
Welch t-test	Тест для сравнения двух средних. Не требует одинаковой дисперсии в группах (в этом отличие Уэлча от классического t-теста). Использует t-распределение, которое учитывает, что дисперсию мы оценили по данным. При большом n почти совпадает с z-test	Revenue, данные после CUPED
z-score	Число стандартных ошибок между наблюдаемой разницей и нулём	Внутри z-test
Двусторонний тест	Ищем разницу в любую сторону (B лучше или хуже), поэтому p-value считается по двум «хвостам»	Все тесты в приложении
Нормальное распределение и ЦПТ	Колоколообразное распределение. Центральная предельная теорема: средние больших выборок распределены почти нормально, даже если сами значения нет. Поэтому z и t тесты вообще работают	Основа z и Welch
χ^2 (хи-квадрат) тест	Сравнивает ожидаемое и фактическое число пользователей по группам	SRM p-value

Интервалы и байесовский подход

Термин	Что это	В приложении
Confidence interval (CI)	Доверительный интервал: диапазон правдоподобных значений эффекта. Строго: 95% таких интервалов, построенных по разным выборкам, накроют истину. Если CI включает 0, то $p \geq$ alpha	CI (absolute diff)
Credible interval	Байесовский интервал: с вероятностью 95% настоящий эффект лежит внутри, при заданных данных и prior. Читается буквально, как и хочется	Credible interval
Prior и Posterior	Prior: что мы думали об эффекте до данных. Posterior: что думаем после. По умолчанию prior «плоский» (нет мнения), его можно сделать «информативным»	Informative prior
Chance to win	Вероятность, что treatment лучше control (площадь posterior справа от нуля)	Bayesian-карточка
Risk (expected loss)	Ожидаемая потеря, если мы примем решение и окажемся неправы. Показывает цену ошибки, а не только её вероятность	Risk if you ship / keep

Термин	Что это	В приложении
Delta method	Приближённая формула для разброса отношения двух средних (B / A). Благодаря ей Bayesian-расчёт мгновенный, без Монте-Карло	Под капотом Bayesian
Bootstrap	Метод: много раз берём выборку с возвращением из имеющихся данных и каждый раз считаем разницу. Разброс этих разниц показывает неопределённость без предположений о распределении	Bootstrap-панель
Percentile CI	Интервал из 2.5% и 97.5% перцентилей bootstrap-разностей	Bootstrap CI

Ошибки, мощность и размер выборки

Термин	Что это	В приложении
Alpha	Допустимая вероятность ложной победы (обычно 5%). Задаёт порог значимости	Alpha
Ошибка I рода (false positive)	Тест показал эффект, которого нет. Её вероятность равна alpha	A/A панель
Ошибка II рода (false negative)	Тест не заметил настоящий эффект. Её вероятность beta = 1 − power	Упражнение 1
Power (мощность)	Вероятность заметить настоящий эффект. Обычно целятся в 80%	Power calculator
MDE	Minimum Detectable Effect: самый маленький эффект, который вы хотите уметь заметить. Чем меньше MDE, тем больше пользователей нужно	Power calculator
Размер выборки	Сколько пользователей нужно, чтобы достичь заданных alpha, power и MDE	Required sample size
Статистическая и практическая значимость	Результат может быть значимым, но слишком маленьким, чтобы иметь смысл для бизнеса. Смотрите на размер эффекта и интервал, а не только на p-value	Uplift и CI
Множественные сравнения	Чем больше метрик и вариантов проверяешь, тем больше шанс на случайную «победу». В приложении пока не моделируется	Ограничения

Улучшения и ловушки

Термин	Что это	В приложении
CUPED	Controlled-experiment Using Pre-Experiment Data. Метод снижения шума: из метрики вычитается часть, предсказанная поведением пользователя до теста. Оценка эффекта остаётся несмещённой, интервал становится уже	Apply CUPED
Ковариата, theta	Ковариата: «до-тестовая» метрика, по которой делается поправка. Theta: коэффициент поправки	Панель CUPED
Variance reduction	Доля шума, убранная CUPED. Приблизительно равна квадрату корреляции до/после	Variance removed
Peeking (подсматривание)	Проверка результата много раз по ходу теста и остановка при первой «победе». Резко увеличивает долю ложных побед	График peeking, A/A
Fixed horizon	Честный режим: срок и размер выборки фиксируются заранее, результат смотрим один раз в конце	A/A: «один раз в конце»

Термин	Что это	В приложении
Sequential testing	Семейство методов, которые делают подсматривание допустимым за счёт поправок. В приложении пока нет	Идея для развития
SRM	Sample Ratio Mismatch: фактическое распределение по группам не совпадает с запланированным. Обычно признак бага, и результатам верить нельзя	SRM p-value
Тяжёлый хвост, lognormal	Распределение, в котором редкие значения огромны (чеки). Из-за них среднее и дисперсия сильно «прыгают». Lognormal: логарифм значения распределён нормально	Tail heaviness (sigma)
Корреляция	Число от −1 до 1: насколько две величины двигаются вместе. Чем выше корреляция до и во время теста, тем лучше работает CUPED	corr(pre, post)